



Bilgisayar Mühendisliği

Veri Bilimi

2025-2026 Bahar Dönemi Final Projesi Raporu

Full Name: İSA ŞEBİB

Student No: 1306220177

1. Problem Tanımı

Kredi riski, bir borç verenin borçlunun geri ödeme yükümlülüklerini yerine getirememesi durumunda karşılaşılabileceği finansal kayıp riskidir. Bankalar ve fintech şirketleri, kredi başvurularını değerlendirirken bu riski doğru tahmin edememek ciddi mali kayıplara yol açabilmektedir. Geleneksel yöntemler çoğunlukla yalnızca kredi puanı ve gelir düzeyini göz önünde bulundururken, makine öğrenimi tabanlı yaklaşımlar çok daha fazla değişkeni aynı anda analiz ederek daha güvenilir tahminler üretebilmektedir.

Bu proje kapsamında üç temel araştırma sorusu ele alınmıştır:

- Kredi geçmişi uzunluğu, temerrüt (default) olasılığını nasıl etkiler?
- Hangi kredi amacı en yüksek temerrüt riskini taşımaktadır ve bu durum faiz oranlarıyla nasıl örtüşmektedir?
- Üç mühendislik özelliğinden hangisi (istihdam istikrarı oranı, gelire göre kredi oranı, kredi yük endeksi) temerrüdü en iyi tahmin etmektedir?

Bu sorular, hem akademik analiz hem de gerçek dünya bankacılık uygulamaları açısından kritik öneme sahiptir.

2. Veri Seti ve Kaynağı

Bu çalışmada Kaggle platformunda "Credit Risk Dataset" adıyla yayımlanan açık veri seti kullanılmıştır.

Özellik	Detay
Kaynak	Kaggle — laotse/credit-risk-dataset
Lisans	CC0: Public Domain
Ham Kayıt Sayısı	32,581
Temizleme Sonrası	32,574
Sütun Sayısı	12 (ham) → 20 (özellik mühendisliği sonrası)
Hedef Değişken	loan_status (0 = İyi, 1 = Temerrüt)
Temerrüt Oranı	%21.82

Veri seti; borçlunun yaşı, geliri, istihdam süresi, kredi miktarı, faiz oranı, kredi amacı, ev sahipliği durumu, kredi notu ve kredi geçmişi uzunluğu gibi değişkenleri içermektedir. Veri seti CC0 lisansı ile kamuya açık olup ticari ve akademik çalışmalarda serbestçe kullanılabilir.

2.1 Veri Temizleme

Ham veri seti iki sütunda eksik değer içermekteydi:

- person_emp_length: 895 eksik değer → 0 ile dolduruldu (işsiz varsayımı)
- loan_int_rate: 3,116 eksik değer → medyan değeriyle dolduruldu (aykırı değerlere karşı dayanıklılık için)

Aykırı değer analizi sonucunda:

- person_age > 100 olan 4 kayıt silindi
- person_emp_length > 60 olan 3 kayıt silindi

Temizleme işlemi sonrasında analize hazır 32,574 kayıt kalmıştır.

2.2 Özellik Mühendisliği

Ham değişkenlerin açıklayıcı gücünü artırmak için sekiz yeni özellik türetilmiştir:

Özellik	Formül / Tanım	Amaç
loan_to_income_ratio	loan_amnt / person_income	Borç karşılanabilirliği
risk	Eşik tabanlı sınıflandırma	Risk seviyesi (Düşük/Orta/Yüksek)
emp_stability_ratio	emp_length / (age - 18)	İstihdam istikrarı
loan_burden_index	loan_to_income_ratio x loan_int_rate	Bileşik finansal baskı
risk_adjusted_income	Daha önce temerrüt varsa gelir x 0.7	Riske göre düzeltilmiş gelir
credit_maturity_index	cred_hist_length / person_age	Kredi olgunluğu
customer_category	Kural tabanlı segmentasyon	Müşteri profili
red_flag	Geçmiş temerrüt VE kredi > 1.000\$	İkili uyarı göstergesi

3. Yöntem

3.1 Keşifsel Veri Analizi (EDA)

Veri setinin yapısını anlamak için beş farklı görselleştirme türü kullanılmıştır:

- Pearson korelasyon matrisi (ısı haritası) — değişkenler arası doğrusal ilişkileri ortaya koymak için
- Müşteri risk seviyesi dağılımı (çubuk grafik) — risk kategorilerinin dengesini görselleştirmek için
- Yaş - Gelir ilişkisi (dağılım grafiği) — demografik örüntüleri ve temerrüt konumlanmasını incelemek için
- Kredi faiz oranı dağılımı (histogram) — faiz oranlarının normalliğini ve merkezi eğilimini görmek için
- Gelire göre kredi oranı dağılımı (KDE eğrisi ile) — risk eşiklerini doğrulamak için

3.2 Araştırma Sorusu Analizleri

Her araştırma sorusu için ayrı bir analiz bloğu oluşturulmuş; gruplandırma, istatistik ve görselleştirme bir arada sunulmuştur. Böylece her soruya veri odaklı yanıtlar üretilmiştir.

3.3 Sınıflandırma Modeli

Temerrüt tahmini için Lojistik Regresyon modeli seçilmiştir. Bu tercih şu gerekçelere dayanmaktadır:

- Yorumlanabilir katsayılar: Her özelliğin temerrüt olasılığına katkısı doğrudan okunabilir
- Temel modelleme için yeterliliği: Ders kapsamı tek savunulabilir model gerektirmekte olup karmaşık hiperparametre optimizasyonu beklenmemektedir
- Finans sektöründeki yaygınlığı: Bankacılık uygulamalarında standart bir yaklaşım olması

Model kurulum adımları şöyle sıralanmıştır:

- loan_intent değişkeni pd.get_dummies() ile ikili sütunlara dönüştürüldü (drop_first=True ile çoklu doğrusallık önlendi)
- Araştırma sorularından elde edilen bulgulara dayanarak 11 özellik seçildi
- Veri %80 eğitim / %20 test olarak bölündü; sınıf dengesini korumak için stratify=y kullanıldı
- StandardScaler ile özellikler ölçeklendirildi
- LogisticRegression(random_state=42, max_iter=1000) ile model eğitildi

4. Bulgular

4.1 EDA Bulguları

Korelasyon matrisi analizinde dikkat çekici yüksek korelasyonlar tespit edilmiştir:

Değişken Çifti	Korelasyon	Yorum
loan_percent_income ↔ loan_to_income_ratio	0.999	Neredeyse özdeş değişkenler
person_income ↔ risk_adjusted_income	0.981	Türetilmiş değişken ilişkisi
person_age ↔ cb_person_cred_hist_length	0.878	Yaş arttıkça kredi geçmişi uzuyor
loan_amnt ↔ loan_int_rate	0.14	Beklentinin aksine zayıf ilişki

Risk dağılımı analizi veri setinin dengesiz yapısını gözler önüne sermiştir: Düşük Risk %76.2, Yüksek Risk %22.6, Orta Risk %4.1. Faiz oranları normal dağılım sergilemekte olup ortalaması %11.01, medyanı %10.99'dur.

4.2 Araştırma Sorusu Sonuçları

Araştırma Sorusu 1 — Kredi Geçmişi Uzunluğu ve Temerrüt:

Hipotez reddedilmiştir. Beklentinin aksine doğrusal bir ilişki gözlemlenmemiştir. Temerrüt oranı 0-5 yıl grubunda %22.52'den 15-20 yıl grubuna doğru %20.78'e gerilemekte; ancak 20+ yıl grubunda %25.94 ile en yüksek değerine ulaşmaktadır. Bu sürpriz artış, küçük örneklem büyüklüğüne (n=212) ve yaşlı borçluların farklı risk profillerine bağlanabilir.

Araştırma Sorusu 2 — Kredi Amacı ve Temerrüt:

Hipotez reddedilmiştir. En yüksek temerrüt oranı PERSONAL değil, DEBTCONSOLIDATION (borç konsolidasyonu) kredilerinde gözlemlenmiştir (%28.59). En düşük risk ise VENTURE (girişim) kredilerindedir (%14.82). Kritik bulgulardan biri, bankanın riski yanlış fiyatlandırmasıdır: tüm kredi amaçlarında faiz oranları yalnızca 0.23 puanlık bir aralıkta seyretmekte (%10.95 - %11.18), oysa temerrüt oranları 13.77 puanlık bir farka sahiptir. Bu durum önemli bir fiyatlandırma verimsizliğine işaret etmektedir.

Araştırma Sorusu 3 — Özellik Karşılaştırması:

Özellik	Temerrüt Korelasyonu	Yön	Değerlendirme
loan_burden_index	0.454	Pozitif	En güçlü
loan_to_income_ratio	0.386	Pozitif	Güçlü
emp_stability_ratio	-0.070	Negatif	Zayıf

Hipotez reddedilmiştir. İstihdam istikrarı oranı neredeyse hiçbir tahmin gücü taşımamaktadır ($r = -0.07$). loan_burden_index, kredi miktarını faiz oranıyla çarptığı için bileşik finansal baskıyı tek bir değişkenle yakalaması sayesinde en güçlü tahmin edici olarak öne çıkmıştır.

4.3 Model Sonuçları

Metrik	Değer
Doğruluk (Accuracy)	%83.61
ROC-AUC Skoru	0.8323
İyi Kredi Kesinliği (Precision)	0.85
İyi Kredi Duyarlılığı (Recall)	0.95
Temerrüt Kesinliği (Precision)	0.71
Temerrüt Duyarlılığı (Recall)	0.41

Karmaşıklık matrisi incelendiğinde modelin 4.860 iyi krediyi doğru sınıflandırdığı, 587 temerrüdü yakaladığı, 234 iyi krediyi yanlışlıkla temerrüt olarak işaretlediği ve 834 gerçek temerrüdü kaçırdığı görülmektedir.

Özellik önem analizinde loan_to_income_ratio en yüksek pozitif katsayıya sahipken (katsayı = +2.05), loan_burden_index negatif bir katsayı almıştır (katsayı = -1.20). Bu görünürde çelişkili sonuç, loan_to_income_ratio ve loan_int_rate ile arasındaki çoklu doğrusallık nedeniyle modelin ağırlıkları dengelemesinden kaynaklanmaktadır.

5. Sınırlamalar

Bu çalışmanın başlıca kısıtları şöyle sıralanabilir:

- Sınıf dengesizliği: Veri setinin %78.18'i iyi kredi (%21.82'si temerrüt) sınıfından oluşmaktadır. Bu dengesizlik, modelin temerrütleri yakalamadaki başarısını olumsuz etkilemiş; temerrüt duyarlılığını %41'de tutmuştur. Gerçek bir bankacılık uygulamasında 834 kaçırılan temerrüt ciddi finansal kayıplara yol açabilir.
- Çoklu doğrusallık: `loan_burden_index`, `loan_to_income_ratio` ve `loan_int_rate` değişkenlerinin çarpımından elde edildiği için bu üç değişken model içinde birbirini etkiliyor ve katsayılar yorumlanabilirliğini yitiriyor. Daha özenli bir özellik seçim süreci bu sorunu giderebilirdi.
- Model seçimi: Lojistik Regresyon, doğrusal olmayan örüntüleri yakalamakta yetersiz kalabilir. Random Forest veya Gradient Boosting gibi topluluk yöntemleri daha iyi performans sağlayabilirdi.
- Fiyatlandırma sorusu: RQ2'de tespit edilen fiyatlandırma verimsizliği (temerrüt oranlarıyla örtüşmeyen faiz oranları), gerçek bankaların farklı risk değerlendirme metodolojileri kullandığını akla getirmektedir. Kamuya açık bu veri seti, kurumsal fiyatlandırma kararlarının tüm karmaşıklığını yansıtmıyor olabilir.
- Veri temsili: Veri setinin hangi ülkeden, hangi zaman diliminden derlendiği ve hangi demografik grupları kapsadığı belirsizdir; bu durum bulguların genellenebilirliğini kısıtlamaktadır.

6. Öğrenilenler

Bu proje, aşağıdaki teknik ve kavramsal derslerin özümsemesini sağlamıştır:

- EDA, varsayımları test etmek için vazgeçilmezdir: `loan_amnt` ile `loan_int_rate` arasındaki zayıf korelasyon ($r=0.14$) ve 20+ yıllık müşterilerdeki temerrüt artışı, verilere dayanmadan ortaya koyulamayacak bulgulardı. Gerçek veriler sezgilerimizi her zaman doğrulamaz.
- Özellik mühendisliği modeli güçlendirir, ancak dikkat gerektirir: `loan_burden_index` en güçlü korelasyona (0.454) ulaştı; ne var ki bileşenlerinin modelde ayrı ayrı yer alması çoklu doğrusallığa yol açtı. Türetilmiş özellikler faydalı olmakla birlikte dikkatlice yönetilmelidir.
- Doğruluk, tek başına yeterli bir metrik değildir: %83.61 doğruluk kulağa etkileyici gelse de %41'lik temerrüt duyarlılığı, modelin asıl hedef açısından — kötü kredileri tespit etmek — yetersiz kaldığını ortaya koymaktadır. Dengesiz veri setlerinde F1-skor ve ROC-AUC çok daha bilgilendiricidir.
- Yapay zeka araçları bir partner olmakla birlikte eleştirel düşüncüyü ikame edemez: RQ1 analizi başlangıçta yanlış yorumlandı; 20+ yıl grubundaki temerrüt artışı gözden kaçırıldı. RQ3 görselleştirmesinde de iki özellik karşılaştırılırken üçüncüsü grafiğe dahil edilmedi. Bu hatalar, yapay zeka çıktılarının manuel doğrulama gerektirdiğini açıkça gösterdi.
- İş bağlamı analizi zenginleştirir: DEBTCONSOLIDATION kredilerinin borç konsolidasyonu yapan, dolayısıyla halihazırda mali sıkıntı içindeki müşterilerden kaynaklanması gibi nüanslar, sonuçların yalnızca teknik değil gerçek dünya açısından da anlamlı olmasını sağladı.
- Veri bilimi iş akışı döngüseldir: Modelleme sırasında ortaya çıkan bulgular (ör. çoklu doğrusallık) geriye gidip özellik seçimini sorgulatabilir. Veri bilimi projelerinde doğrusal bir ilerleme değil, yinelemeli bir süreç söz konusudur.

Veri kaynağı: Kaggle — *laotse/credit-risk-dataset* (CC0: Public Domain)

Prompt günlüğü ve tüm kodlar için *GitHub reposuna* bakınız.